

Rapid Anxiety and Depression Diagnosis in Young Children Enabled by Wearable Sensors and Machine Learning

Guilherme Oliveira Santos
Universidade Federal de Ouro Preto, March, 2022

ABSTRACT

Este artigo apresenta uma nova abordagem para diagnosticar ansiedade e depressão em crianças pequenas. Atualmente, o diagnóstico requer horas de entrevistas clínicas estruturadas e questionários padronizados distribuídos por dias ou semanas. Foi proposto o uso de uma tarefa de indução de medo de 90 enquanto o participante é monitorado usando um sensor vestível. Com ferramentas de aprendizado de máquina e dados extraídos da fase de 20 segundos mais crítica da tarefa de indução de medo é possível prever o algum tipo de diagnóstico internalizante. Esses resultados apontam para o uso futuro de essa abordagem em um ambiente clínico para diagnosticar crianças com distúrbios internalizantes.

This paper presents a new approach for diagnosing anxiety and depression in young children. Currently, diagnosis requires hours of structured clinical interviews and standardized questionnaires spread over days or weeks. We propose the use of a 90-second fear induction task during which time participant motion is monitoring using a commercially available wearable sensor. Machine learning and data extracted from the most clinically feasible 20-second phase of the task are used to predict diagnosis in a sample of children with and without an internalizing diagnosis. These results point toward the future use of this approach in a clinical setting for diagnosing children with internalizing disorders.

KEYWORDS

LR,VM,DT,kNN

ACM Reference Format:

Guilherme Oliveira Santos. 2023. Rapid Anxiety and Depression Diagnosis in Young Children Enabled by Wearable Sensors and Machine Learning. In *Proceedings of ACM Conference (Conference'17)*. ACM, New York, NY, USA, 5 pages. <https://doi.org/10.1145/nnnnnnn.nnnnnnn>

1 INTRODUÇÃO

Cerca de 20% das crianças sofrem com distúrbios internalizantes, como depressão e ansiedade, que podem começar ainda na fase pré-escolar e prejudicar o desenvolvimento socioemocional. Se não tratados, esses distúrbios podem levar a problemas significativos de saúde mais tarde na vida, como abuso de substâncias, outras psicopatologias, risco aumentado de suicídio e prejuízo funcional substancial. Diante disso, é essencial identificar precocemente as crianças em risco, mas a abordagem atual de coleta de dados subjetivos leva horas e tem limitações. Para resolver esse problema, há um trabalho recente que se concentra no desenvolvimento de métodos de observação instrumentados para avaliar psicopatologias de forma rápida e objetiva. Em um estudo piloto, os participantes foram equipados com um dispositivo de medição inercial para rastrear seus movimentos durante uma tarefa de indução de medo. Em outro estudo, modelos estatísticos foram capazes de identificar participantes com diagnóstico de distúrbios internalizantes com 75% de

precisão usando dados extraídos de apenas 20 segundos da tarefa. Contudo, esses modelos requerem o conjunto de dados de treinamento completo, limitando sua aplicabilidade a dispositivos com recursos limitados. O estudo atual descreve uma metodologia de processamento refinada e explora várias abordagens de modelagem para reduzir os requisitos computacionais e melhorar a qualidade do diagnóstico previsto pelo modelo.

2 ANÁLISE CRÍTICA

2.1 Informações sobre o artigo.

2.1.1 *Autores.* Ryan S. McGinnis, Ellen W. McGinnis, et al.

2.1.2 *Institutos de ensino.* University of Michigan, University of Vermont.

2.1.3 *Data e local.* Julho 2018, International Conference of Engineering in Medicine and Biology Society. Honolulu, Hawaii.

2.2 Tipo de pesquisa

O artigo descreve um estudo de algo presumivelmente melhor baseado em observações de dados de aprendizado de máquina para classificar diagnósticos de transtornos internalizantes.

2.3 Motivação

A motivação para construção do artigo origina-se da eficácia do uso de sensores vestíveis no diagnóstico, em comparação com outros métodos. Os autores destacam que a compreensão dessas técnicas podem ajudar a desenvolver estratégias para promover o uso de inteligências artificiais.

2.4 Objetivos

O objetivo do artigo é discutir a alta prevalência de transtornos internalizantes em crianças, e como a avaliação atual pode ser limitada, propor uma nova abordagem. Alguns dos objetivos específicos abordados no projeto foram: Mineração de dados por sensores vestíveis, processamento de dados por meio de machine learning e diagnóstico.

2.5 Hipótese

A hipótese principal do artigo não é explicitamente mencionada, mas pode ser inferida a partir do objetivo do estudo ao avaliar se dados de sensores diagnosticam transtornos internalizantes.

2.6 Problema e Justificativa


O problema em questão refere-se aos transtornos de internalização em crianças, que muitas vezes são diagnosticados tardiamente. Esses transtornos podem incluir ansiedade, depressão, transtornos alimentares e outros problemas emocionais que afetam negativamente a vida da criança.

A falta de diagnóstico precoce pode levar a um agravamento dos sintomas e a um impacto significativo na qualidade de vida da criança. Por isso, é importante buscar soluções para identificar esses transtornos o mais cedo possível, de forma a possibilitar um tratamento adequado e melhorar a saúde mental e emocional da criança.

Assim, a justificativa para fornecer uma solução significativa para o problema é clara: é necessário agir para evitar que os transtornos de internalização em crianças sejam diagnosticados tardiamente, o que pode levar a consequências graves a curto e longo prazo. A identificação precoce desses transtornos é fundamental para garantir a saúde emocional e mental das crianças, permitindo que elas cresçam de maneira saudável e equilibrada.

3 MÉTODOS

O estudo consistiu em medir o movimento da criança durante uma tarefa de indução de medo, utilizando um cinto com um sensor IMU. Com essas características e alguns dados obtidos que serão abordados melhor adiante, foram treinados modelos de classificação binária usando aprendizado supervisionado, que relacionam as características dos sinais do IMU com diagnósticos internalizantes.



3.1 Projeto Experimental

Este trecho descreve o design experimental de um estudo que coletou dados de 63 crianças entre 3 e 7 anos de idade e seus cuidadores primários, com o objetivo de avaliar o diagnóstico interno dessas crianças. Foram realizadas avaliações multimodais, incluindo entrevistas diagnósticas, em 61 das crianças. Com base nessas avaliações, 21 participantes foram identificados como tendo um diagnóstico internalizante. A amostra de crianças foram predominantemente branca, viviam em famílias de dois pais e era composta por 57% de meninas. Os dados foram coletados por meio de questionários, tarefas comportamentais e entrevistas diagnósticas, em um laboratório universitário. O estudo foi aprovado pelo Comitê de Ética da Universidade de Michigan. O trecho em questão descreve especificamente uma tarefa comportamental chamada "Tarefa da Cobra", que foi projetada para provocar respostas de medo e ansiedade nas crianças. Os comportamentos das crianças durante a fase de Ameaça Potencial da tarefa foram examinados em detalhes. Depois da Tarefa da Cobra, as crianças tiveram tempo para brincar com o administrador e discutir suas experiências.


3.2 Medindo o movimento da criança durante a "Tarefa da Cobra"

É descrito como o movimento das crianças foi medido durante a tarefa com cobras. Os participantes usaram um IMU preso à cintura, que registrou a aceleração e a velocidade angular em diferentes direções. Os dados foram filtrados e transformados em um referencial fixo e vertical. Foram obtidos seis séries de dados que representam o movimento horizontal e vertical, bem como a inclinação e o ângulo de rotação do participante. Os dados foram extraídos da fase de ameaça potencial da tarefa com cobras, que durou 20 segundos e ocorreu antes do momento do susto. Essa fase foi escolhida por ser a mais clinicamente viável.




3.3 Modelos para identificar o diagnóstico de internalização

Neste trecho, é descrito os modelos que utilizam os dados dos sensores vestíveis (IMU) durante a tarefa de indução de medo.



Foram extraídas 29 características dos dados, incluindo média, desvio padrão, RMS, curtose, etc. Essas características foram usadas para treinar modelos de classificação binária (SVM, DT,

kNN e LR), que iremos abordar melhor adiante, para diagnosticar transtornos internalizantes. A acurácia dos modelos foi avaliada usando validação cruzada de deixar um sujeito de fora. Foram examinados diferentes conjuntos de características e modelos para determinar a combinação mais precisa. A performance dos modelos foi avaliada pela curva ROC e a área sob a curva (AUC).



3.3.1 Modelo de Identificação SVM. O modelo de máquina de vetores de suporte, ou SVM, é um algoritmo de aprendizado de máquina que ajuda a classificar dados em diferentes categorias. O SVM trabalha encontrando um limite, chamado de hiperplano, que separa os dados em diferentes classes. O objetivo é maximizar a distância entre o hiperplano e os pontos de dados mais próximos de cada classe.

Em outras palavras, o SVM encontra a melhor linha reta (ou plano, se estivermos trabalhando com mais dimensões) que separa duas classes de pontos de dados, de forma que a distância entre essa linha reta e os pontos de dados mais próximos de cada classe seja a maior possível. Essa distância é chamada de margem. O SVM também permite que sejam usados truques matemáticos para lidar com dados que não são linearmente separáveis, permitindo que os pontos de dados sejam mapeados para um espaço de dimensão superior onde eles podem ser separados linearmente.

3.3.2 Modelo de Identificação DT. Árvores de decisão (DT) são modelos de aprendizado de máquina supervisionados que mapeiam observações sobre um objeto para conclusões sobre o valor alvo desse objeto. É uma representação em forma de árvore, onde cada nó interno representa um teste em um atributo, cada ramo representa o resultado desse teste e cada folha representa uma classe ou uma distribuição de probabilidade sobre as classes. O objetivo da árvore de decisão é criar um modelo que preveja o valor alvo de um objeto, aprendendo simples regras de decisão inferidas dos recursos do objeto. A partir da árvore, é possível avaliar a importância de cada recurso para a previsão e interpretar o modelo para entender como cada recurso contribui para a previsão final. Árvores de decisão são frequentemente utilizadas em problemas de classificação e regressão, e são relativamente fáceis de interpretar e implementar.

3.3.3 Modelo de Identificação kNN. O k-Nearest Neighbors (kNN) é um modelo de aprendizado de máquina que pode ser usado tanto para problemas de classificação quanto de regressão. É um modelo simples e intuitivo que se baseia na ideia de que objetos similares tendem a estar próximos uns dos outros. O modelo armazena todas as observações do conjunto de treinamento e, quando é apresentado com um novo objeto, procura os k vizinhos mais próximos desse objeto no espaço de atributos. Em seguida, o modelo usa a classe ou o valor médio desses k vizinhos para prever a classe ou o valor do novo objeto. O valor de k é um hiperparâmetro do modelo e pode ser escolhido de acordo com a natureza do problema. Uma vantagem do kNN é que ele é não paramétrico, ou seja, não faz suposições sobre a distribuição dos dados. No entanto, ele pode ser computacionalmente caro para grandes conjuntos de dados e pode ter problemas com dados com muitas dimensões.

3.3.4 Modelo de Identificação LR. A regressão linear (LR) é um modelo de aprendizado de máquina supervisionado usado para prever um valor contínuo a partir de um conjunto de variáveis explicativas (ou independentes). É uma técnica estatística que busca encontrar a melhor reta para descrever a relação entre uma variável dependente e uma ou mais variáveis independentes. O modelo de regressão linear assume que essa relação pode ser modelada por uma função linear, o que significa que o valor da variável dependente é uma combinação linear das variáveis independentes mais um termo de erro. O modelo procura encontrar os coeficientes (ou pesos) que melhor ajustam a reta aos dados de treinamento. Uma vez que o modelo é treinado, ele pode ser usado para fazer previsões sobre novos dados. A regressão linear é frequentemente usada em problemas de previsão de preços, análise de tendências e análise de correlação entre variáveis. É um modelo simples e fácil de interpretar, mas pode ser limitado por sua suposição de linearidade e por ser sensível a pontos de dados atípicos.

3.4 Métricas

Em resumo, foi utilizado três métricas diferentes para o estudo do caso, a sensibilidade, a especificidade e a acurácia. Iremos abordar essas métricas melhores nas próximas subseções, porém é importante sempre levar em conta essas métricas para avaliar a qualidade do modelo e sua capacidade de fazer previsões precisas e confiáveis.


3.4.1 Sensibilidade. É a capacidade de um modelo de identificar corretamente as amostras positivas (verdadeiros positivos). Em outras palavras, a sensibilidade mede a proporção de amostras positivas que são corretamente identificadas pelo modelo. Por exemplo, se um modelo é capaz de identificar 90% dos casos de uma doença (ou seja, 90% dos verdadeiros positivos), ele tem uma sensibilidade de 0,9.

3.4.2 Especificidade. É a capacidade de um modelo de identificar corretamente as amostras negativas (verdadeiros negativos). Em outras palavras, a especificidade mede a proporção de amostras negativas que são corretamente identificadas pelo modelo. Por exemplo, se um modelo é capaz de identificar 95% dos casos de indivíduos saudáveis (ou seja, 95% dos verdadeiros negativos), ele tem uma especificidade de 0,95.

3.4.3 Acurácia. É a medida geral da precisão do modelo, que mede a proporção de amostras corretamente classificadas pelo modelo (tanto verdadeiros positivos quanto verdadeiros negativos) em relação ao número total de amostras. Em outras palavras, a acurácia mede a proporção de acertos do modelo em relação ao total de previsões feitas. Por exemplo, se um modelo classifica corretamente 90% dos casos, ele tem uma acurácia de 0,9.

4 RESULTADOS

Foram utilizados diferentes modelos de classificação acima (como a regressão logística e o SVM) para avaliar a precisão de diferentes conjuntos de características (como o ANG+ACC+GYR) na identificação de pessoas com diagnóstico de internalização. Foram criados gráficos de dispersão para mostrar a distribuição dos escores-z de duas características. Os pontos azuis representam os participantes com diagnóstico de internalização e os pontos vermelhos correspondem àqueles sem diagnóstico.



Foi observado que o LR e o SVM oferecem a maior precisão em todas as combinações de conjuntos de características. O LR alcançou uma precisão de 80% com o conjunto de características ACC+GYR+ANG, enquanto o SVM alcançou 80% de precisão com o conjunto de características GYR+ANG. A análise das curvas ROC indicou que o modelo de regressão logística é ligeiramente mais discriminativo do que o SVM, com uma AUC de 0,92 em comparação com 0,89 para o SVM. Em geral, o modelo de regressão logística foi mais sensível do que o SVM. Gráficos foram apresentados para ilustrar a precisão da classificação e as curvas

ROC dos melhores modelos de classificação.

ACC	58	53	64	64
GYR	69	59	71	71
ANG	68	71	78	78
ACC+ANG	63	56	64	66
ACC+GYR	66	73	76	75
GYR+ANG	69	69	80	76
ACC+GYR+ANG	69	73	76	80
	DT	kNN	SVM	LR

Os resultados apresentados neste texto demonstram que, quando combinados com a aprendizagem de máquina, 20 segundos de dados de sensores vestíveis extraídos de uma tarefa de indução ao medo podem ser usados para diagnosticar distúrbios internalizantes em crianças jovens com alto nível de precisão e a uma fração do custo e tempo das técnicas de avaliação existentes. Isso significa que a utilização de dados de sensores vestíveis em conjunto com técnicas de aprendizado de máquina pode ser uma maneira altamente eficaz de diagnosticar crianças com distúrbios internalizantes de forma mais acessível e rápida do que as técnicas tradicionais de avaliação. Esses resultados apontam para o futuro uso dessa abordagem para o diagnóstico de crianças com distúrbios internalizantes.

5 IMPLEMENTAÇÃO

Os distúrbios internalizantes, como a ansiedade e a depressão, são comuns em crianças e podem afetar negativamente sua saúde mental e seu desempenho escolar. No entanto, o diagnóstico preciso desses distúrbios pode ser difícil e demorado, muitas vezes envolvendo múltiplas consultas com profissionais de saúde mental e uma variedade de questionários e avaliações.

Atualmente ainda não houve nenhum tipo de implementação desse tipo de trabalho na área, sendo ainda uma lacuna na literatura. Mas, com a descoberta apresentada neste texto, os profissionais de saúde mental poderão usar uma abordagem mais eficiente e precisa para diagnosticar crianças com distúrbios internalizantes. Essa abordagem pode permitir uma intervenção precoce e mais eficaz para esses distúrbios, o que pode levar a melhores resultados a longo prazo para as crianças afetadas.

6 REFERENCES

- Ryan S. McGinnis, et al. Rapid Anxiety and Depression Diagnosis in Young Children Enabled by Wearable Sensors and Machine Learning. July, 2018.
- H. L. Egger and A. Angold, "Common emotional and behavioral disorders in preschool children: presentation, nosology, and epidemiology," *J Child Psychol Psychiatry*, vol. 47, no. 3–4, pp. 313–337, Apr. 2006.
- A. Bittner, H. L. Egger, A. Erkanli, E. Jane Costello, D. L. Foley, and A. Angold, "What do childhood anxiety disorders predict?," *J Child Psychol Psychiatry*, vol. 48, no. 12, pp. 1174–1183, Dec. 2007.
- R. S. McGinnis et al., "Wearable Sensors and Machine Learning Diagnose Anxiety and Depression in Young Children," in 2018 IEEE International Conference on Biomedical and Health Informatics (BHI), Las Vegas, NV, 2018.
- R. S. McGinnis, S. M. Cain, S. P. Davidson, R. V. Vitali, S. G. McLean, and N. C. Perkins, "Validation of Complementary Filter Based IMU Data Fusion for Tracking Torso Angle and Rifle Orientation," presented at the ASME 2014 International Mechanical Engineering Congress and Exposition, Montreal, QC, 2014, p. V003T03A052.